ĐẠI HỌC QUỐC GIA TP. HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN

CS431 – CÁC KỸ THUẬT HỌC SÂU VÀ ỨNG DỤNG

BÀI 11

TRIỂN KHAI VÀ GIÁM SÁT MÔ HÌNH

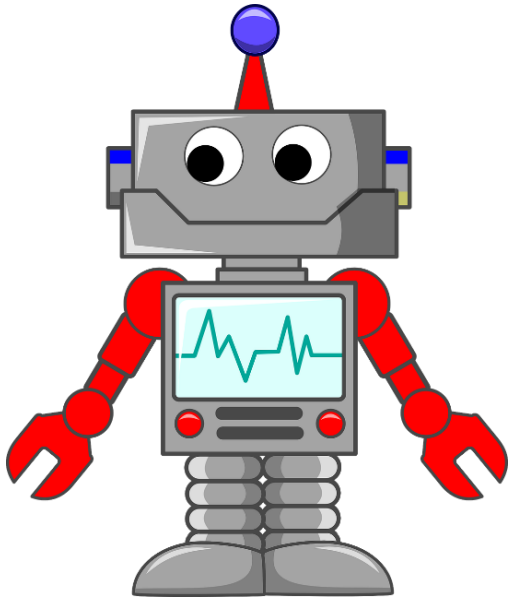

TS. Nguyễn Vinh Tiệp

NỘI DUNG

1. Giới thiệu triển khai mô hình máy học
2. Một số cách tiếp cận triển khai mô hình
3. Triển khai dạng ứng dụng web
4. Triển khai dạng dịch vụ (API)
5. Giám sát mô hình

Giới thiệu về triển khai mô hình máy học

- **Triển khai mô hình máy học** để mô hình dự đoán có thể tiếp cận được với người dùng cuối và các hệ thống khác

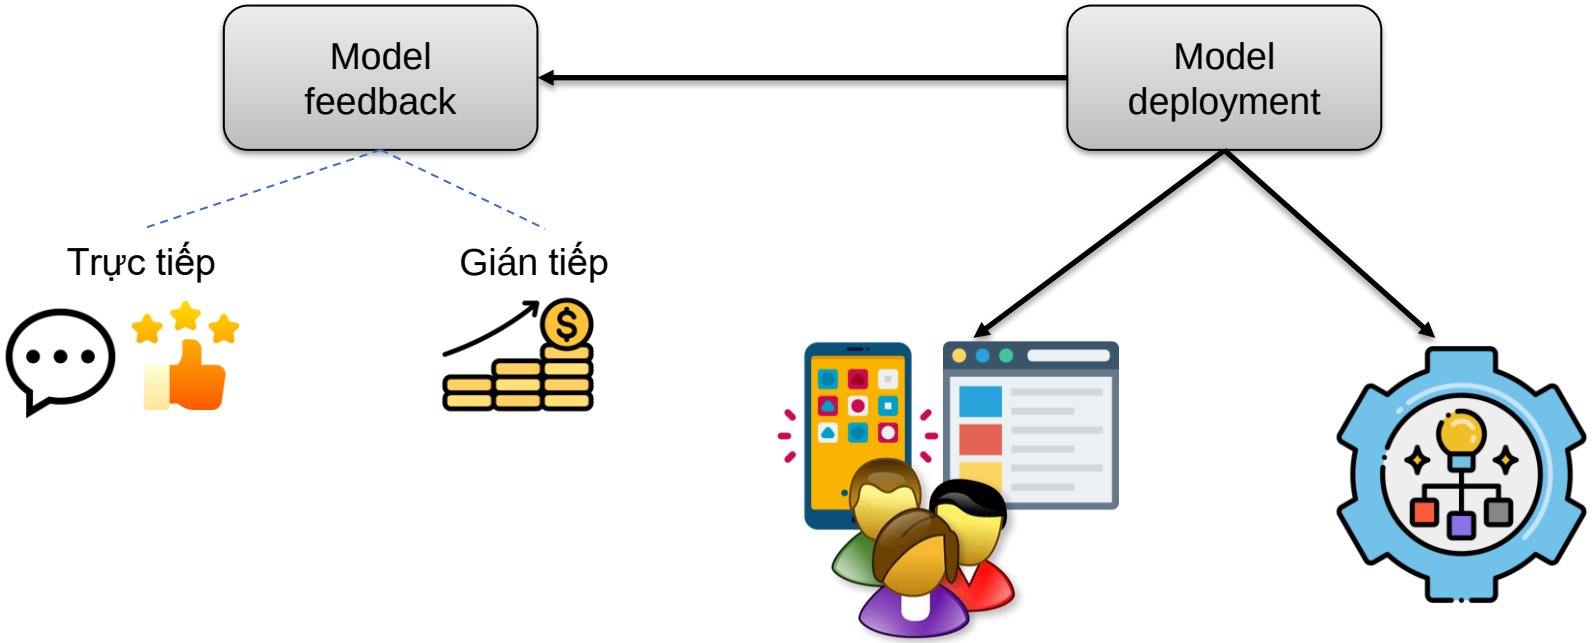

Ứng dụng máy học khắp mọi nơi

- Các ứng dụng tích hợp máy học ngày càng phổ biến
- Sự tồn tại của mô hình máy học trong mắt người dùng:
  - Nhận thức được
  - Không nhận thức được

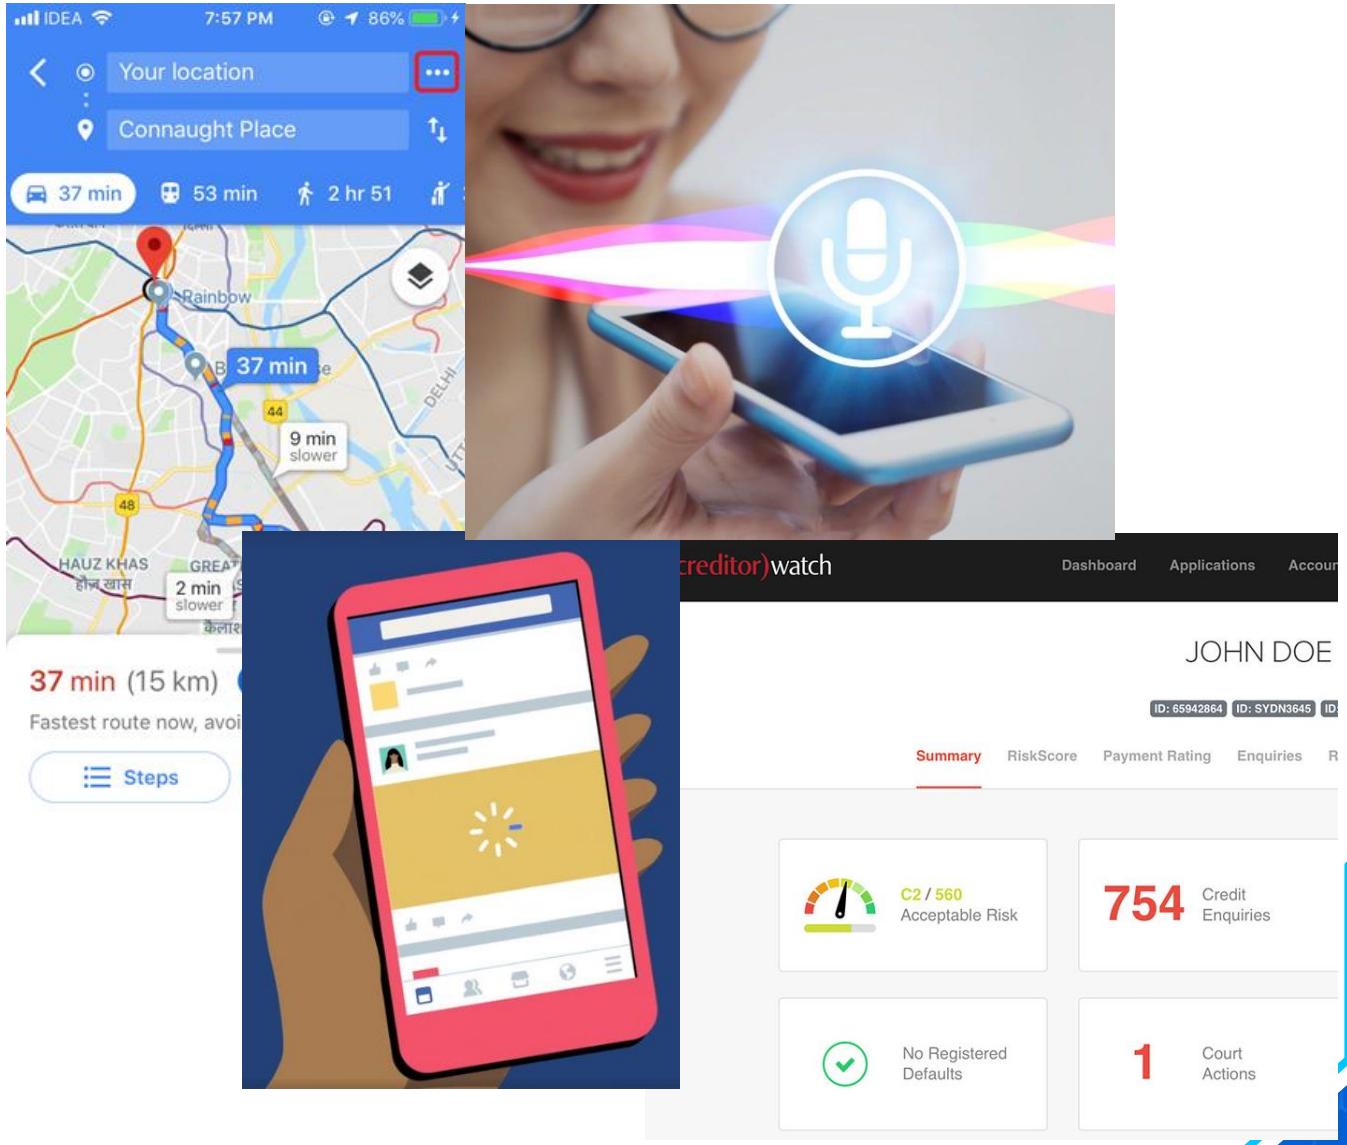

“Technical debt” khi triển khai ứng dụng

- Các đoạn code mô hình (thuật toán) chiếm tỉ trọng rất nhỏ trong một hệ thống có máy học

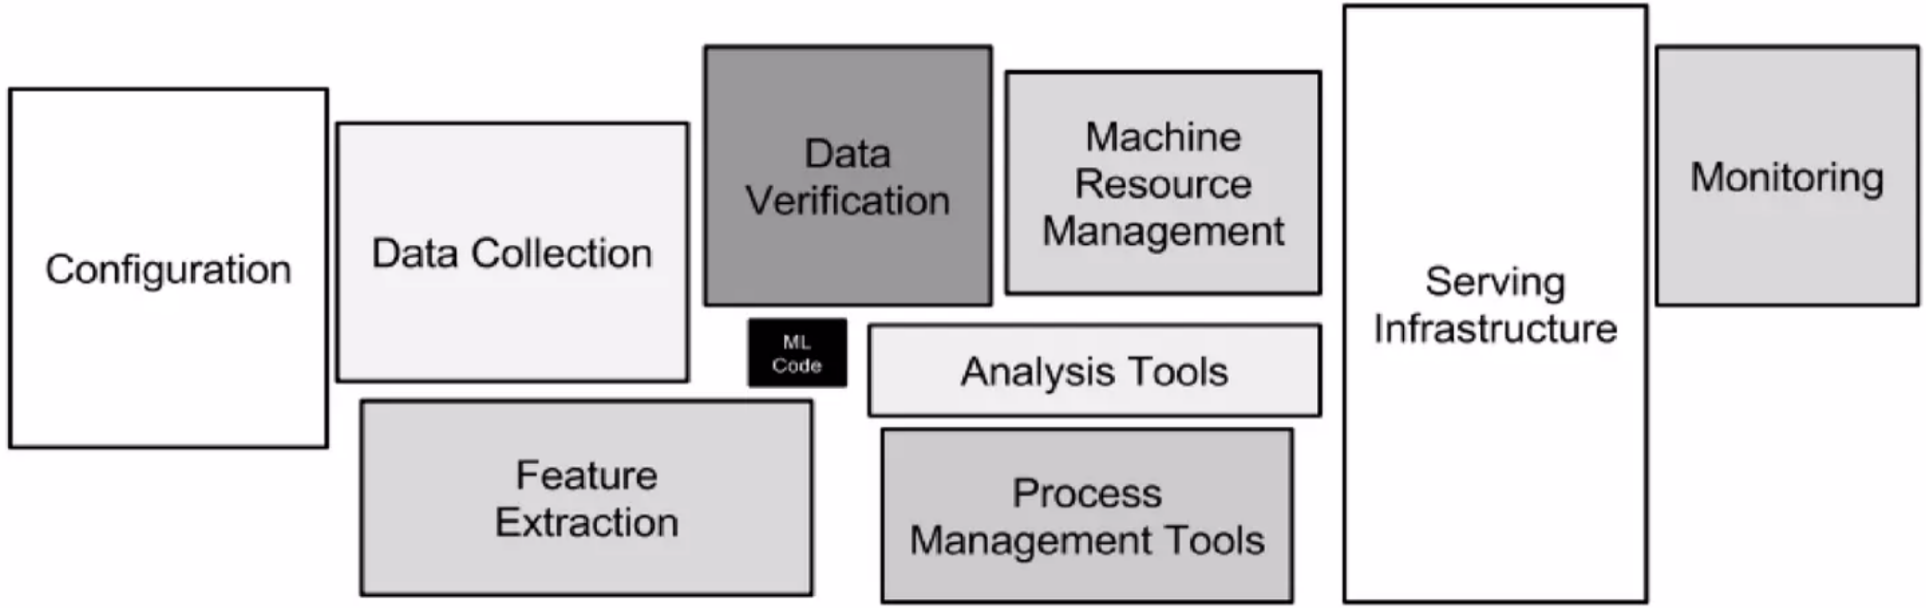

Các công nghệ triển khai chính

Nền tảng dữ liệu lớn

Thư viện máy học

Hạ tầng đóng gói

Nền tảng kết hợp

NỘI DUNG

1. Giới thiệu triển khai mô hình máy học
2. Một số cách tiếp cận triển khai mô hình
3. Triển khai dạng ứng dụng web
4. Triển khai dạng dịch vụ (API)
5. Giám sát mô hình

Mô hình nên triển khai ở đâu?

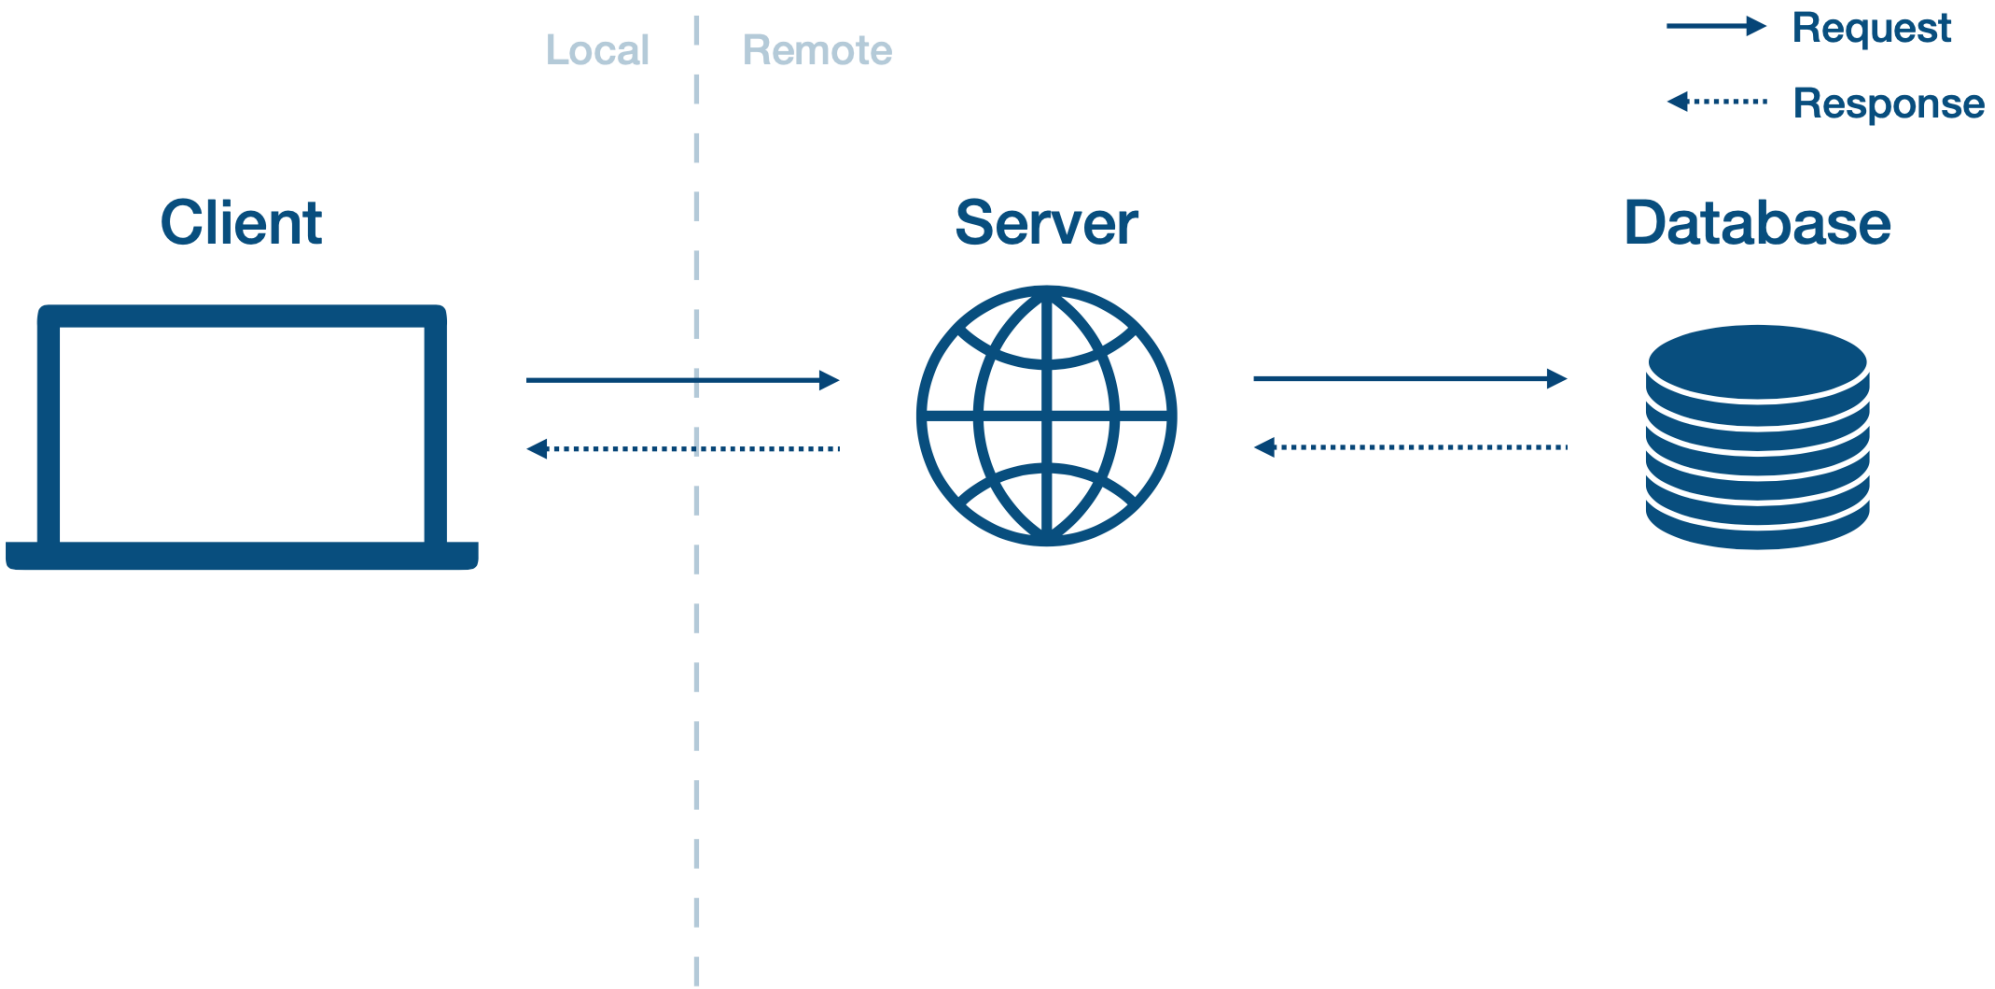

Batch prediction

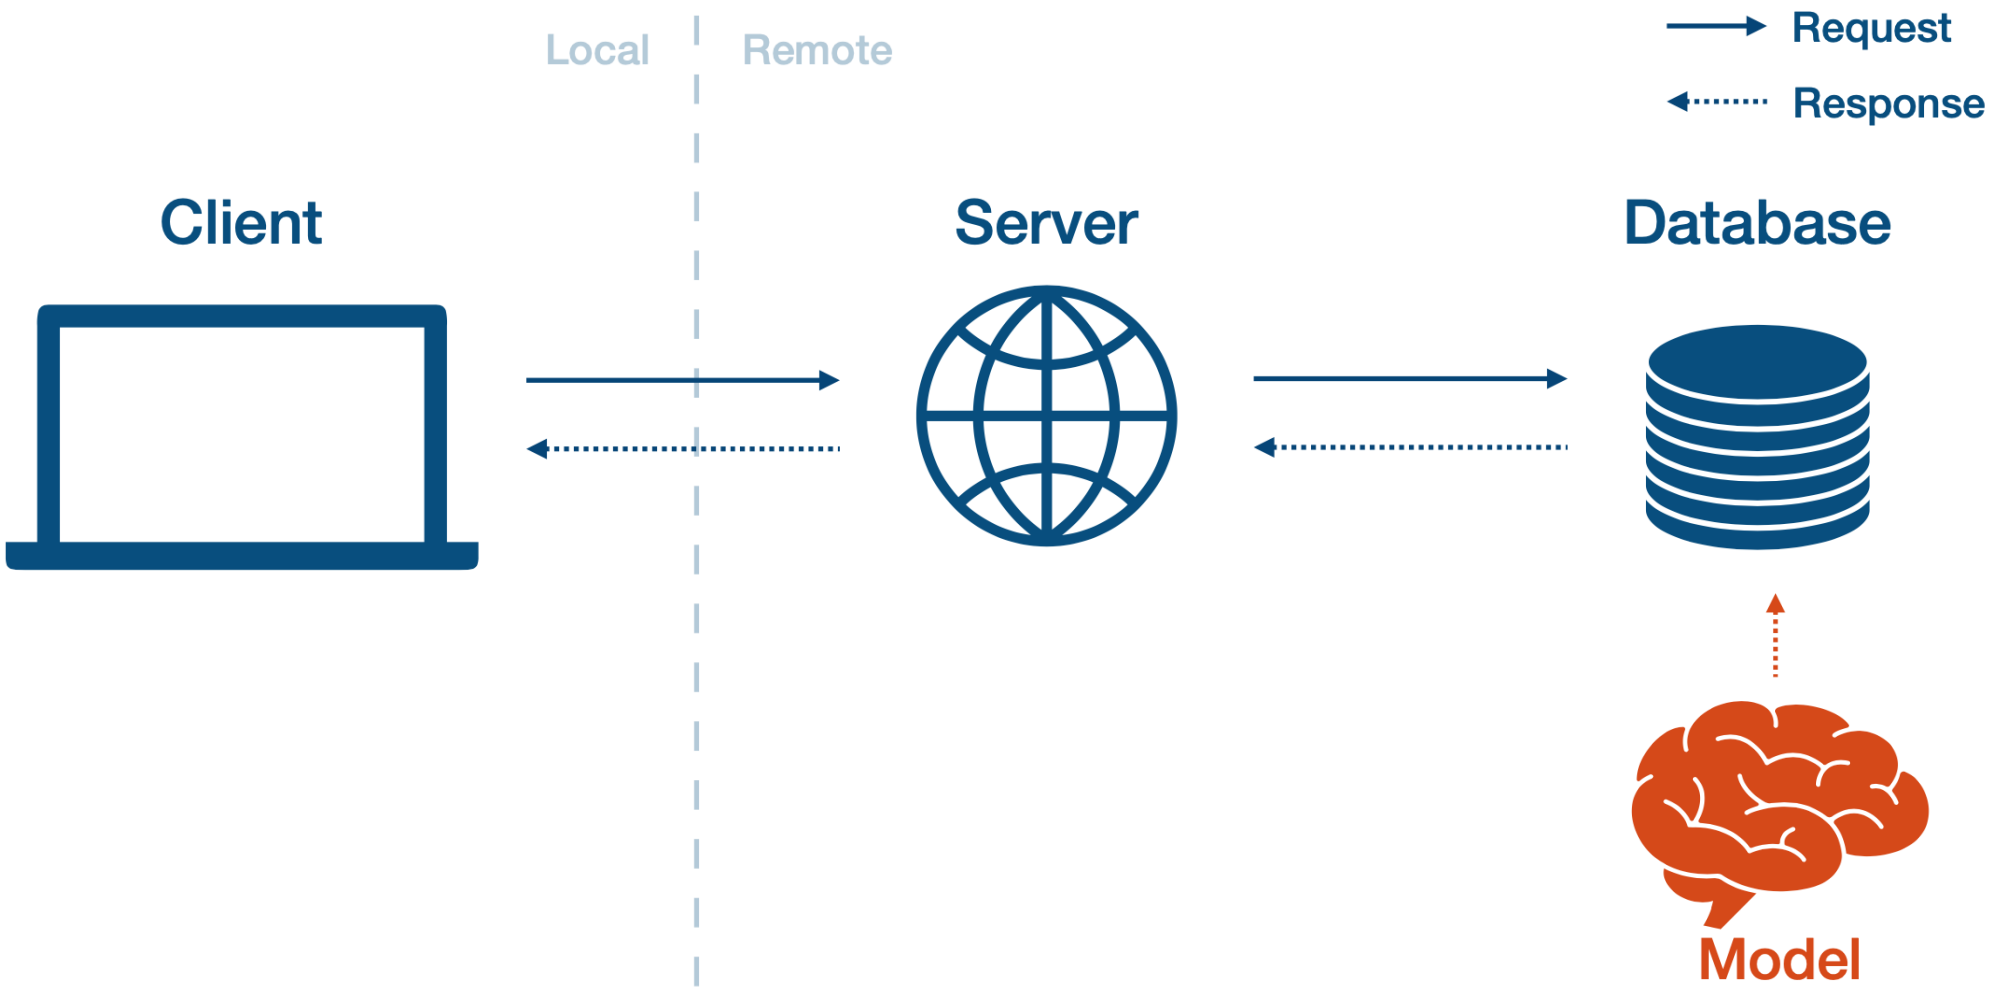

Batch prediction

- Định kỳ chạy mô hình trên dữ liệu mới, lưu vùng đệm (cache) kết quả dự đoán trong database

- Khả thi khi toàn bộ dữ liệu cần chạy đủ nhỏ (VD: 1 dự đoán / 1 user)

Batch prediction

Ưu điểm	Khuyết điểm
• Dễ thực hiện • Độ trễ thấp đối với người dùng	• Dữ liệu phức tạp, khiến mô hình khó tăng quy mô tính toán (scale) • Dữ liệu dự đoán không cập nhật • Mô hình thường trở nên “lỗi thời”

Model-in-service

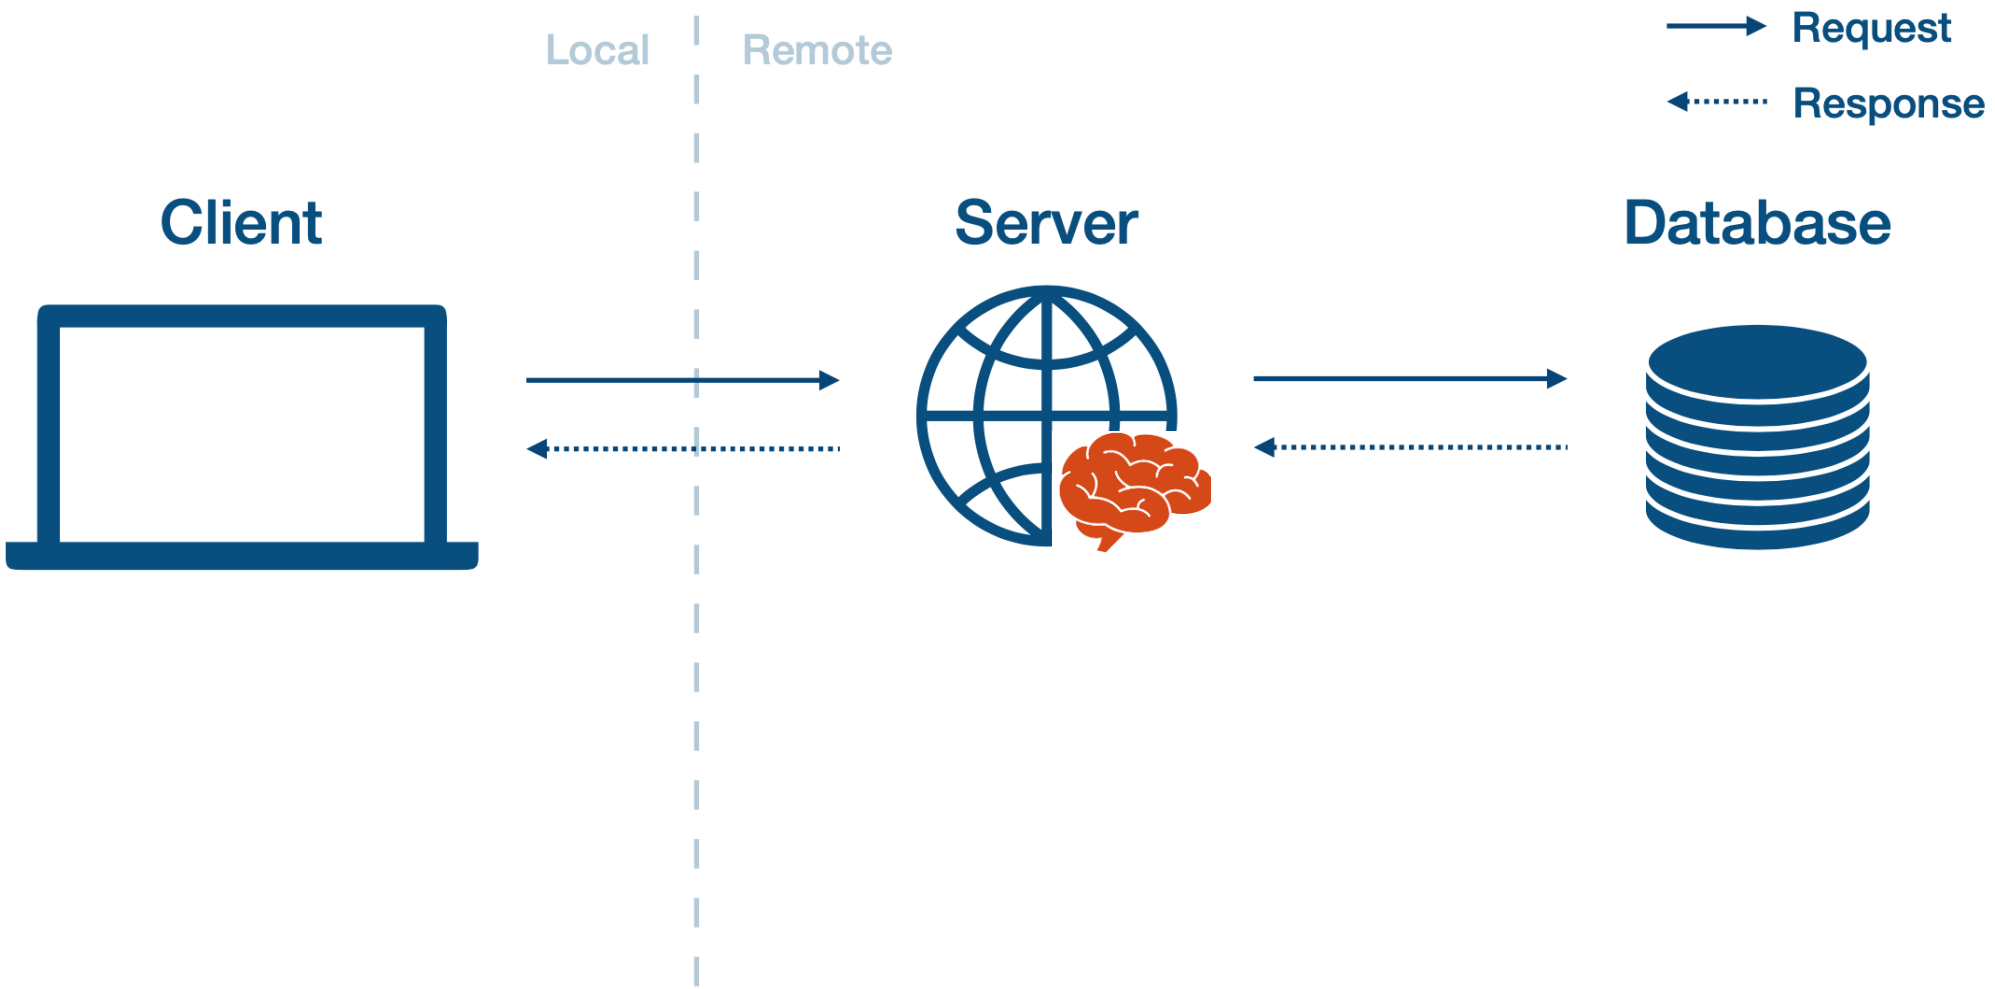

Model-in-service

- Đóng gói mô hình và đặt chung với web server
- Web server tải và gọi mô hình dự đoán khi có yêu cầu (request) từ người dùng

Model-in-service

Ưu điểm	Khuyết điểm
• Tận dụng hạ tầng server hiện có	• Web server có thể được viết bằng ngôn ngữ khác • Mô hình có thể cập nhật thường xuyên hơn code web • Mô hình lớn có thể tốn rất nhiều tài nguyên của web server • Phần cứng của web server có thể không được tối ưu cho mô hình • Mô hình và web server có thể scale khác nhau

Model-as-service

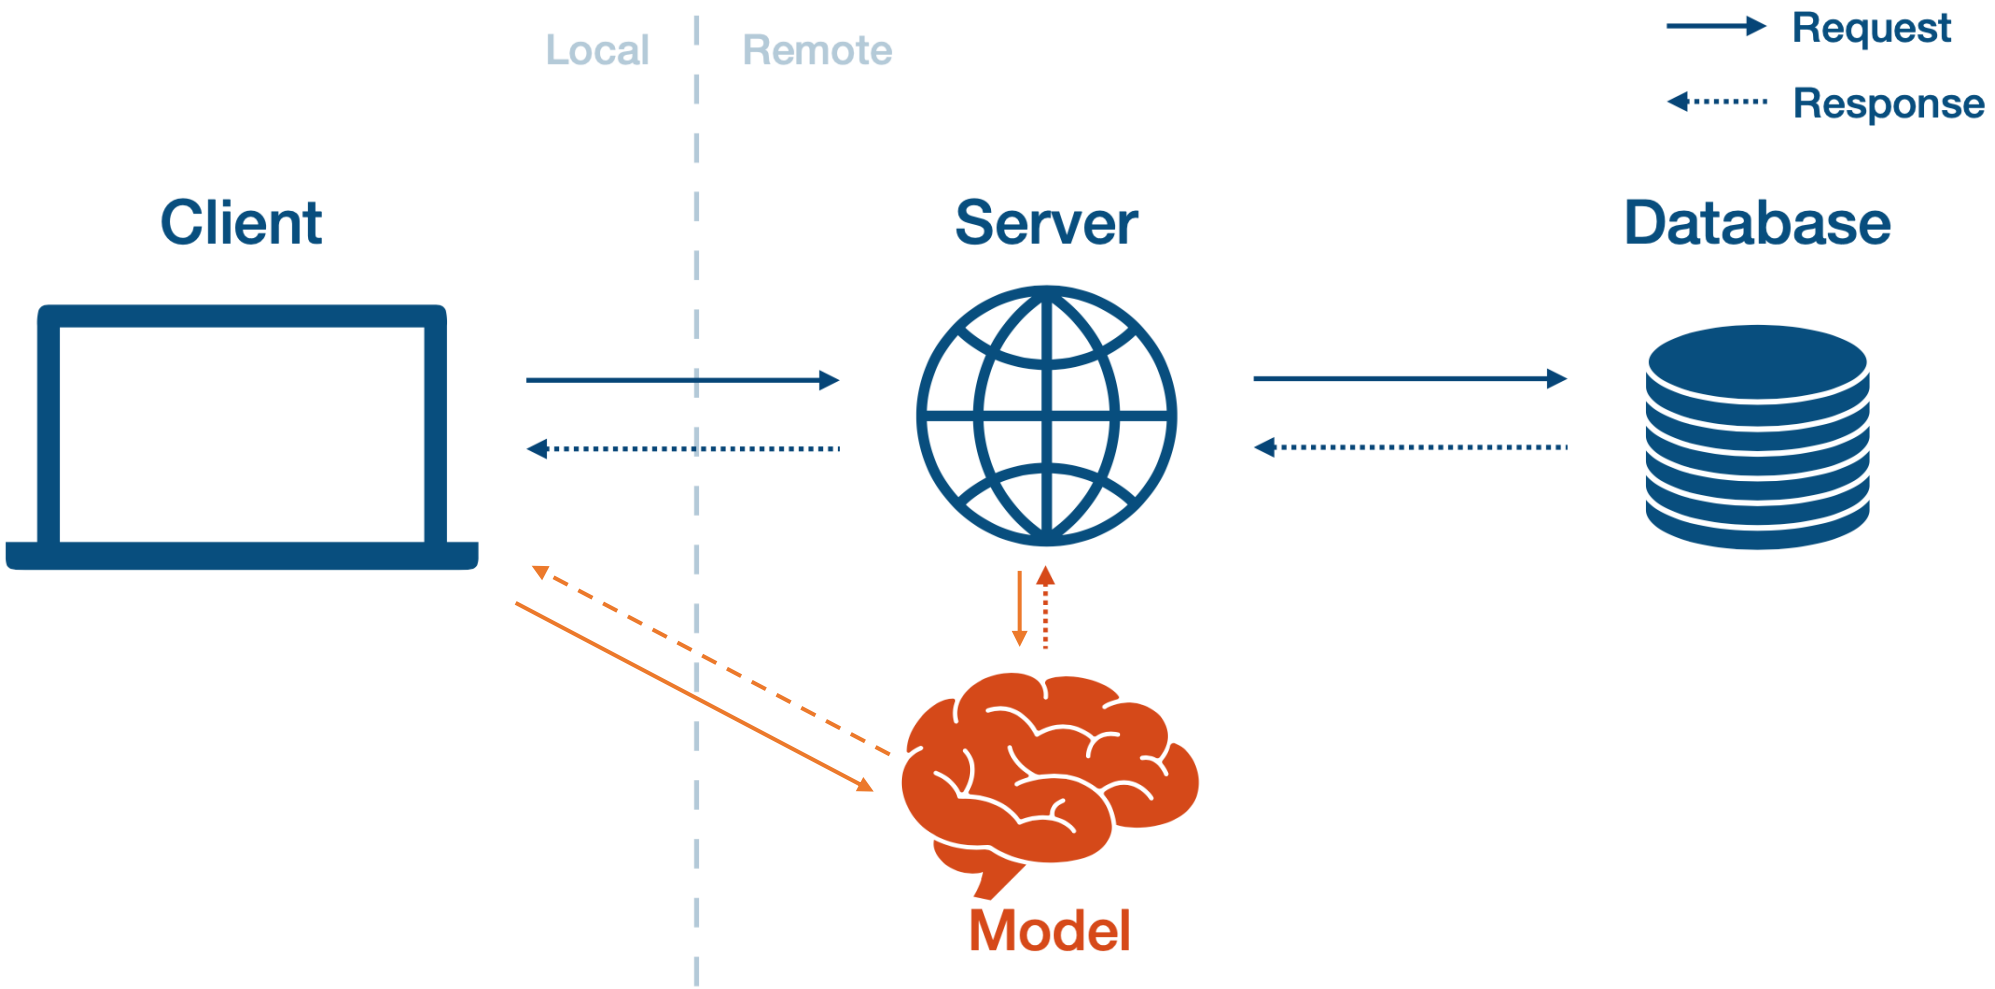

Model-as-service

- Thực thi mô hình trên server riêng
- Web backend tương tác với mô hình bằng cách gọi dịch vụ web và nhận phản hồi ngược lại

Model-as-service

Ưu điểm	Khuyết điểm
• **Tính phụ thuộc**: Mô hình có lỗi không ảnh hưởng (nhiều) đến đến ứng dụng web • **Tính mở rộng**: chọn phần cứng và mở rộng server của mô hình phù hợp • **Tính linh động**: có thể tái sử dụng cho các ứng dụng khác	• Có thể có độ trễ • Phức tạp hơn về hạ tầng

Triển khai mô hình dạng dịch vụ

- REST API
- Quản lý tính phụ thuộc
- Tối ưu hiệu năng
- Mở rộng theo chiều dọc (horizontal scale)
- Triển khai

Edge prediction

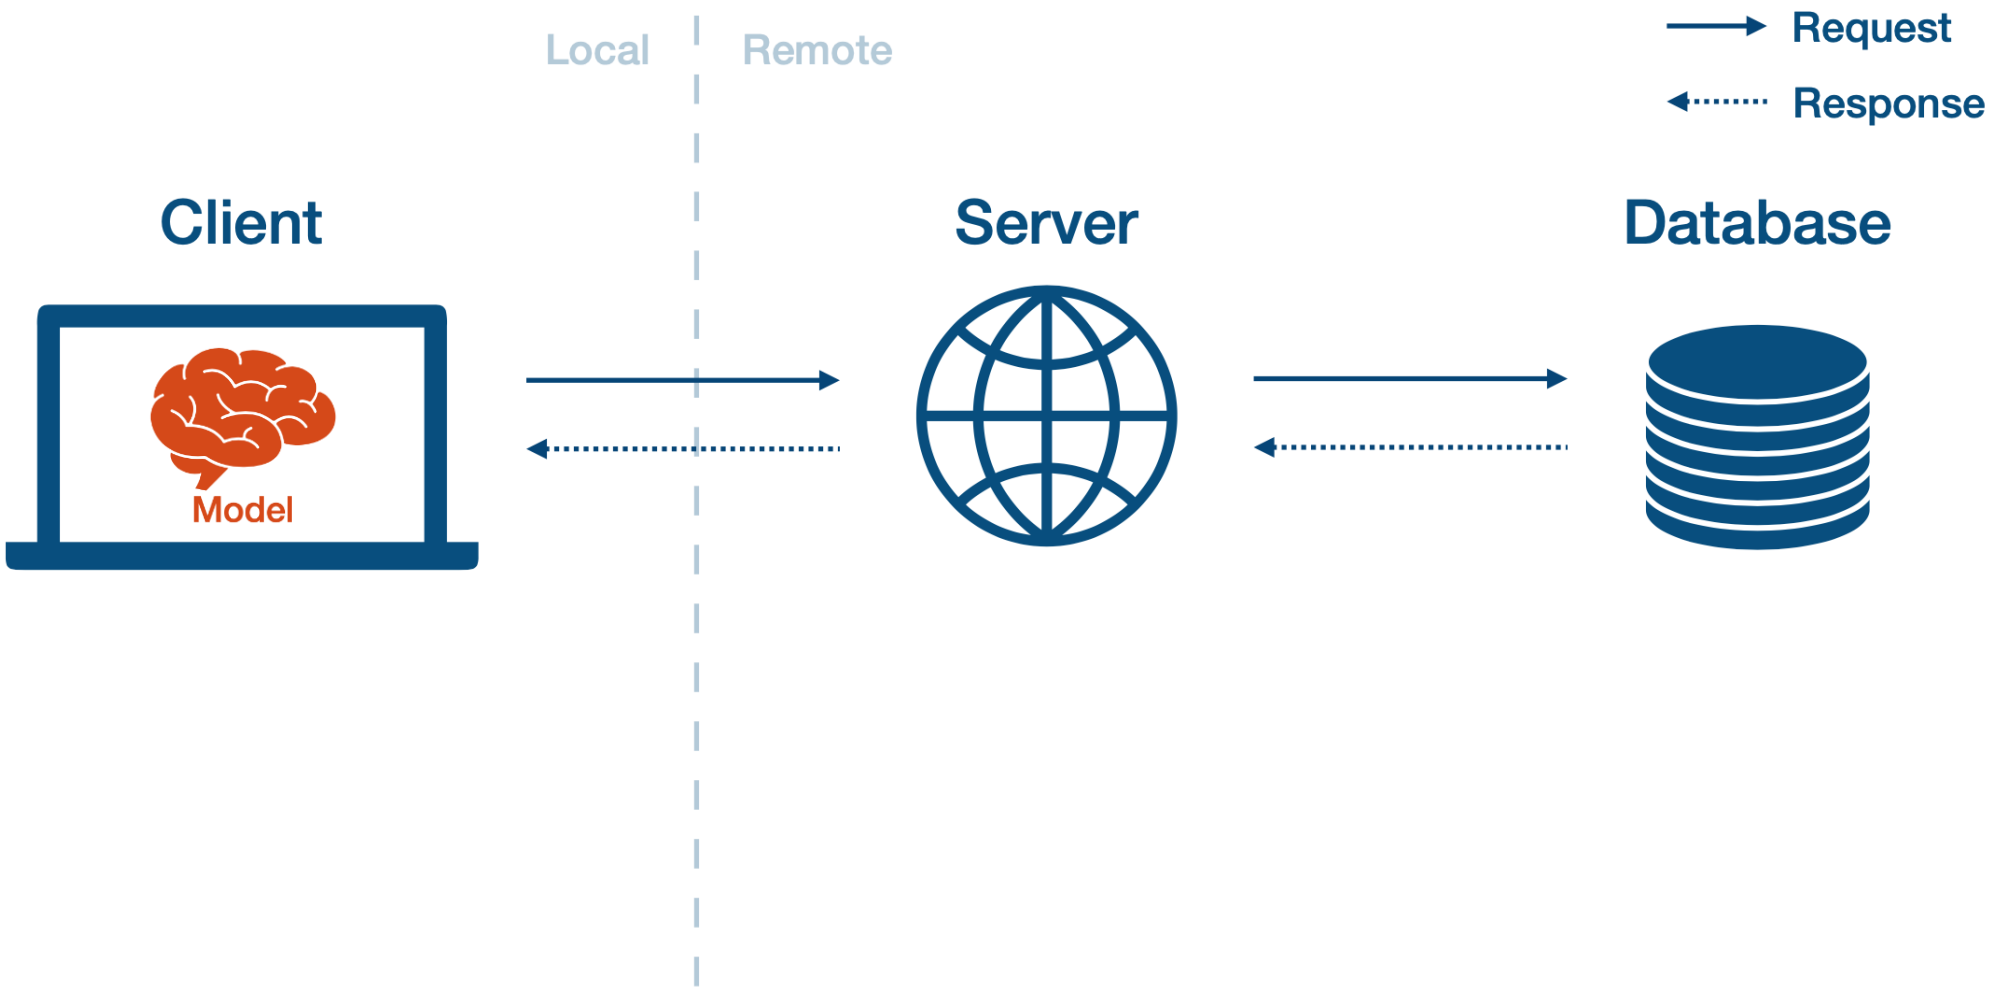

Edge prediction

- Gửi trọng số (weights) của mô hình lên thiết bị biên (edge device)

- Tải mô hình và thực hiện dự đoán trực tiếp từ máy trạm (client)

Edge prediction

Ưu điểm	Khuyết điểm
• Độ trễ thấp • Không cần internet • Bảo mật dữ liệu: không cần chuyển dữ liệu ra khỏi máy trạm	• Tài nguyên máy trạm có hạn • Các thư viện / framework của máy trạm thường không đủ tính năng • Khó cập nhật mô hình • Khó theo dõi và debug

NỘI DUNG

1. Giới thiệu triển khai mô hình máy học
2. Một số cách tiếp cận triển khai mô hình
3. Triển khai dạng ứng dụng web
4. Triển khai dạng dịch vụ web (API)
5. Giám sát mô hình

Tình huống sử dụng

- Demo tính năng chính của mô hình máy học với khách hàng
- Muốn tiếp cận mô hình đến số đông dễ dàng: chỉ cần có internet, không cần cài đặt

Triển khai dạng ứng dụng web

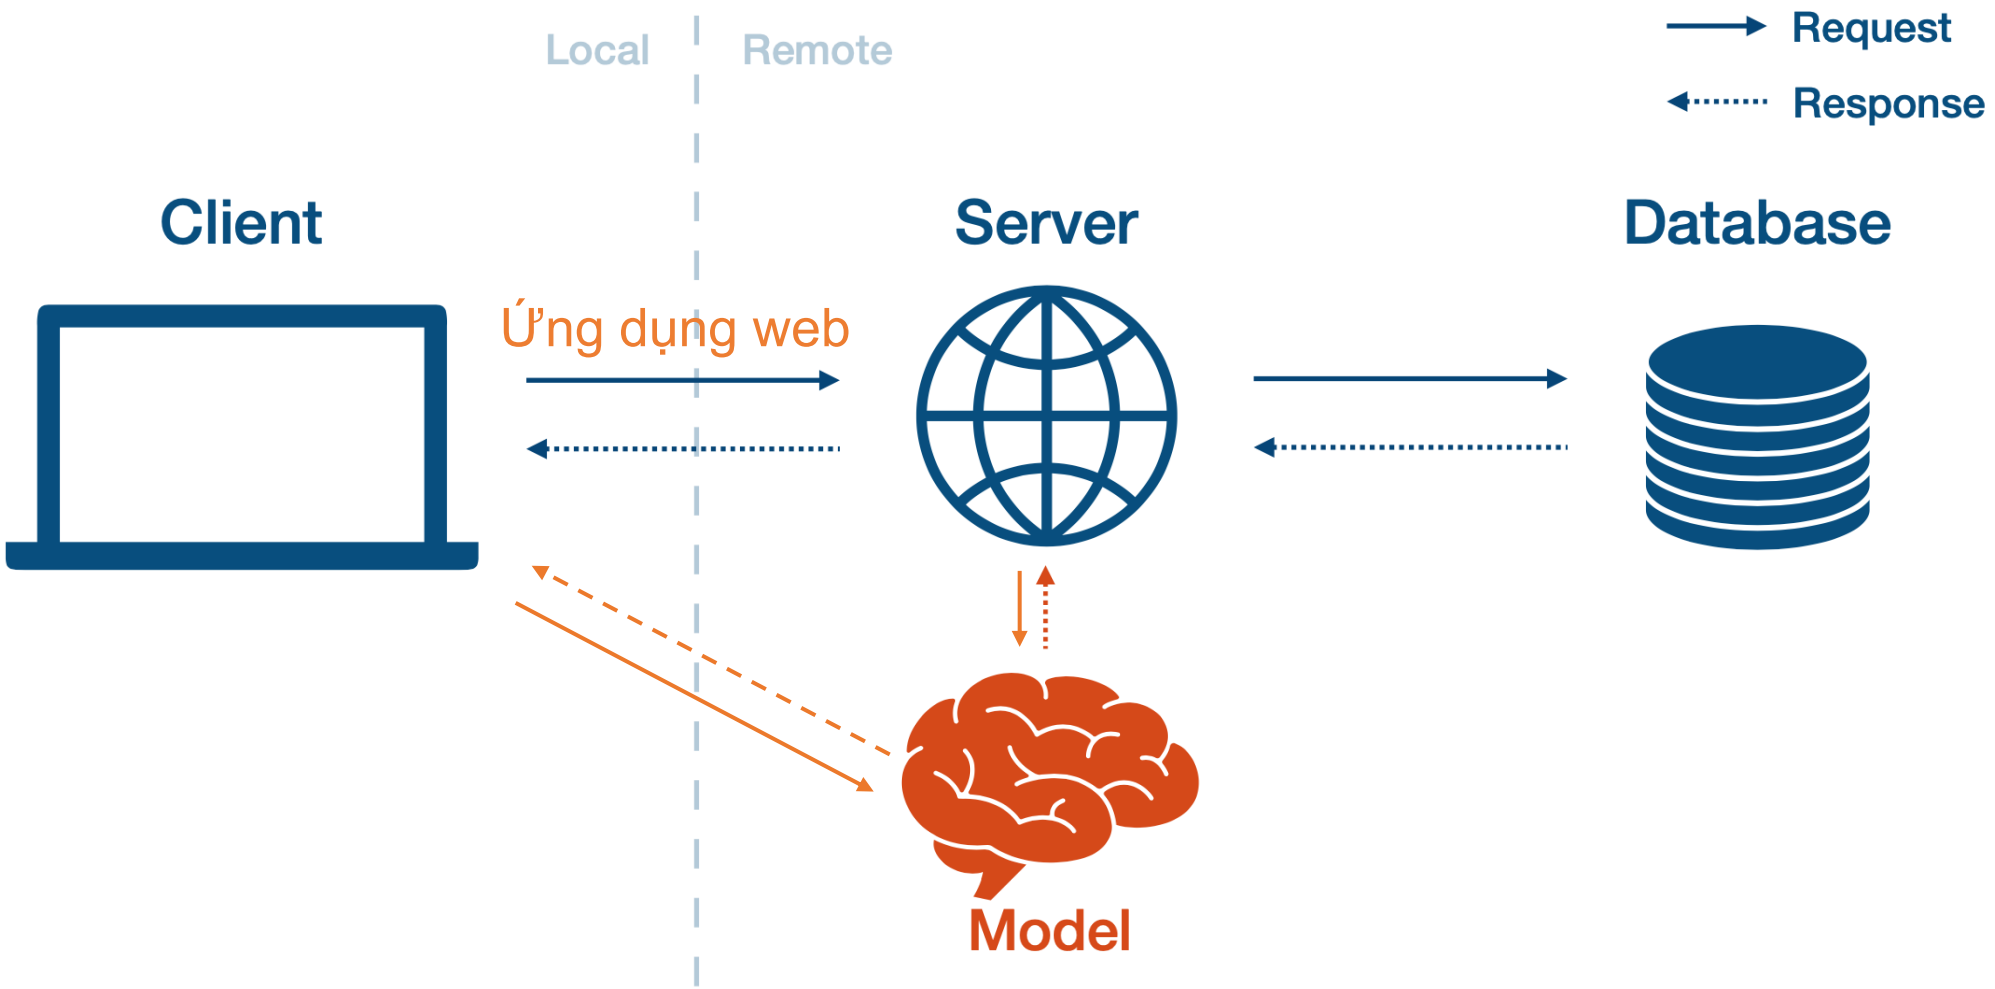

Một số công cụ

Streamlit

gradio

MyApp.py

```
import streamlit as st
import pandas as pd

st.write("""
# My first app
Hello *world!*
""")

df = pd.read_csv("my_data.csv")
st.line_chart(df)
```

My App • Streamlit

My first app

Hello *world!*

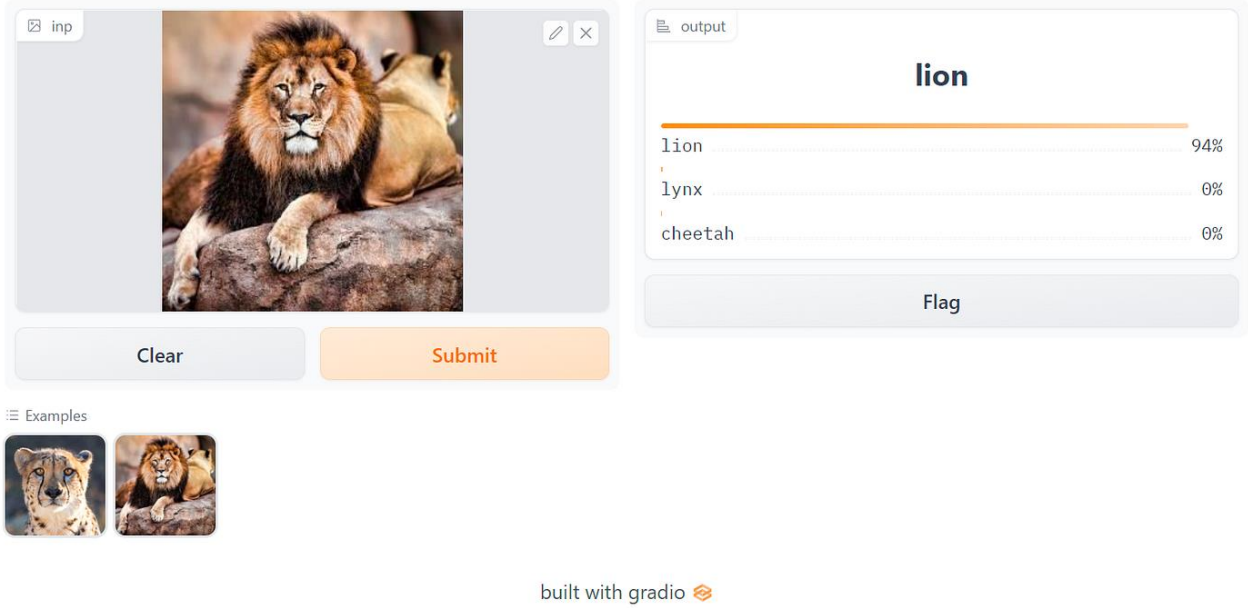

.py

My Favorite Text Editor

Cách học nhanh Streamlit

- Một số control chính khi làm ứng dụng web
  - Label
  - Textbox
  - Button
- Sử dụng công cụ Copilot / ChatGPT để code và chính sửa
- Triển khai trên web

Triển khai ứng dụng web thật

domain.com / demo / price_estimate

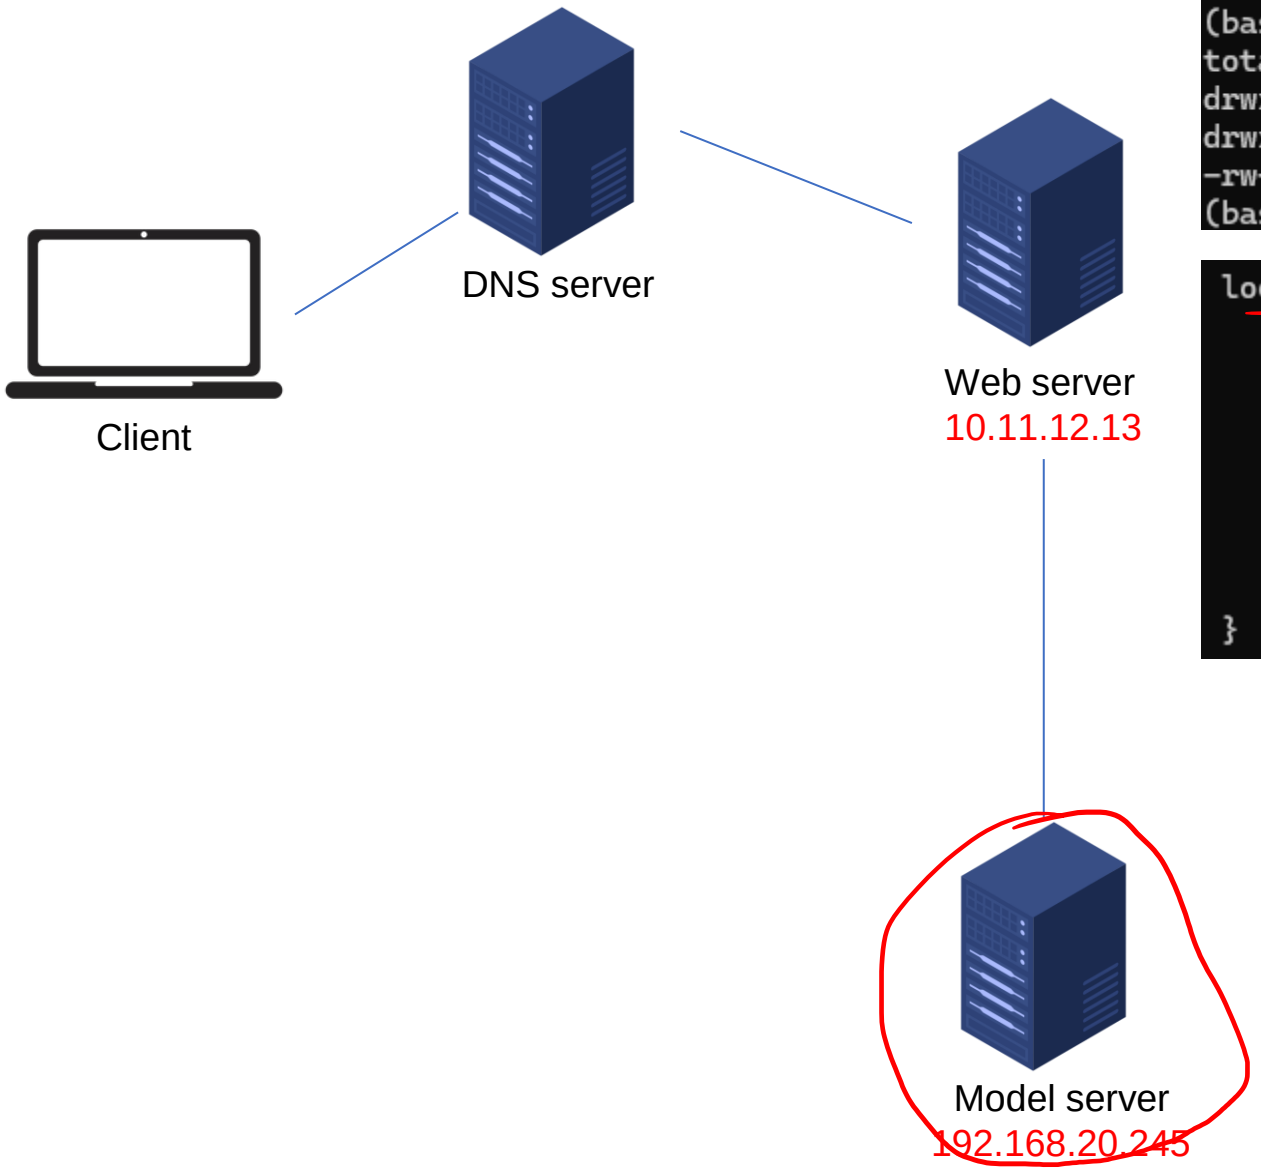


```
(base) mmlab@ubuntu:~$ cd /etc/nginx/sites-available/
(base) mmlab@ubuntu:/etc/nginx/sites-available$ ll
total 24
drwxr-xr-x 2 root root  4096 Jul 31 09:14 ./
drwxr-xr-x 8 root root  4096 Jul 30 11:06 ../
-rw-r--r-- 1 root root 13741 Jul 31 09:14 default
(base) mmlab@ubuntu:/etc/nginx/sites-available$ sudo vim default
```

```
location ^~ /demo/price-estimate/ {
        rewrite /demo/speech2text/(.*) /$1  break;
        proxy_pass http://192.168.20.245:8501;
        proxy_redirect     off;
        proxy_http_version 1.1;
        proxy_set_header Upgrade $http_upgrade;
        proxy_set_header Connection 'upgrade';
        proxy_set_header Host $host;
        proxy_cache_bypass $http_upgrade;
}
```

Bước 1: Cài streamlit

Bước 2: Host dịch vụ web ở một port, VD: 8501

NỘI DUNG

1. Giới thiệu triển khai mô hình máy học
2. Một số cách tiếp cận triển khai mô hình
3. Triển khai dạng ứng dụng web
4. Triển khai dạng dịch vụ (API)
5. Giám sát mô hình

Tình huống sử dụng

- Cung cấp dịch vụ cho bên thứ 3 khai thác
- Tái sử dụng nhiều ứng dụng khác nhau

Triển khai dạng dịch vụ API

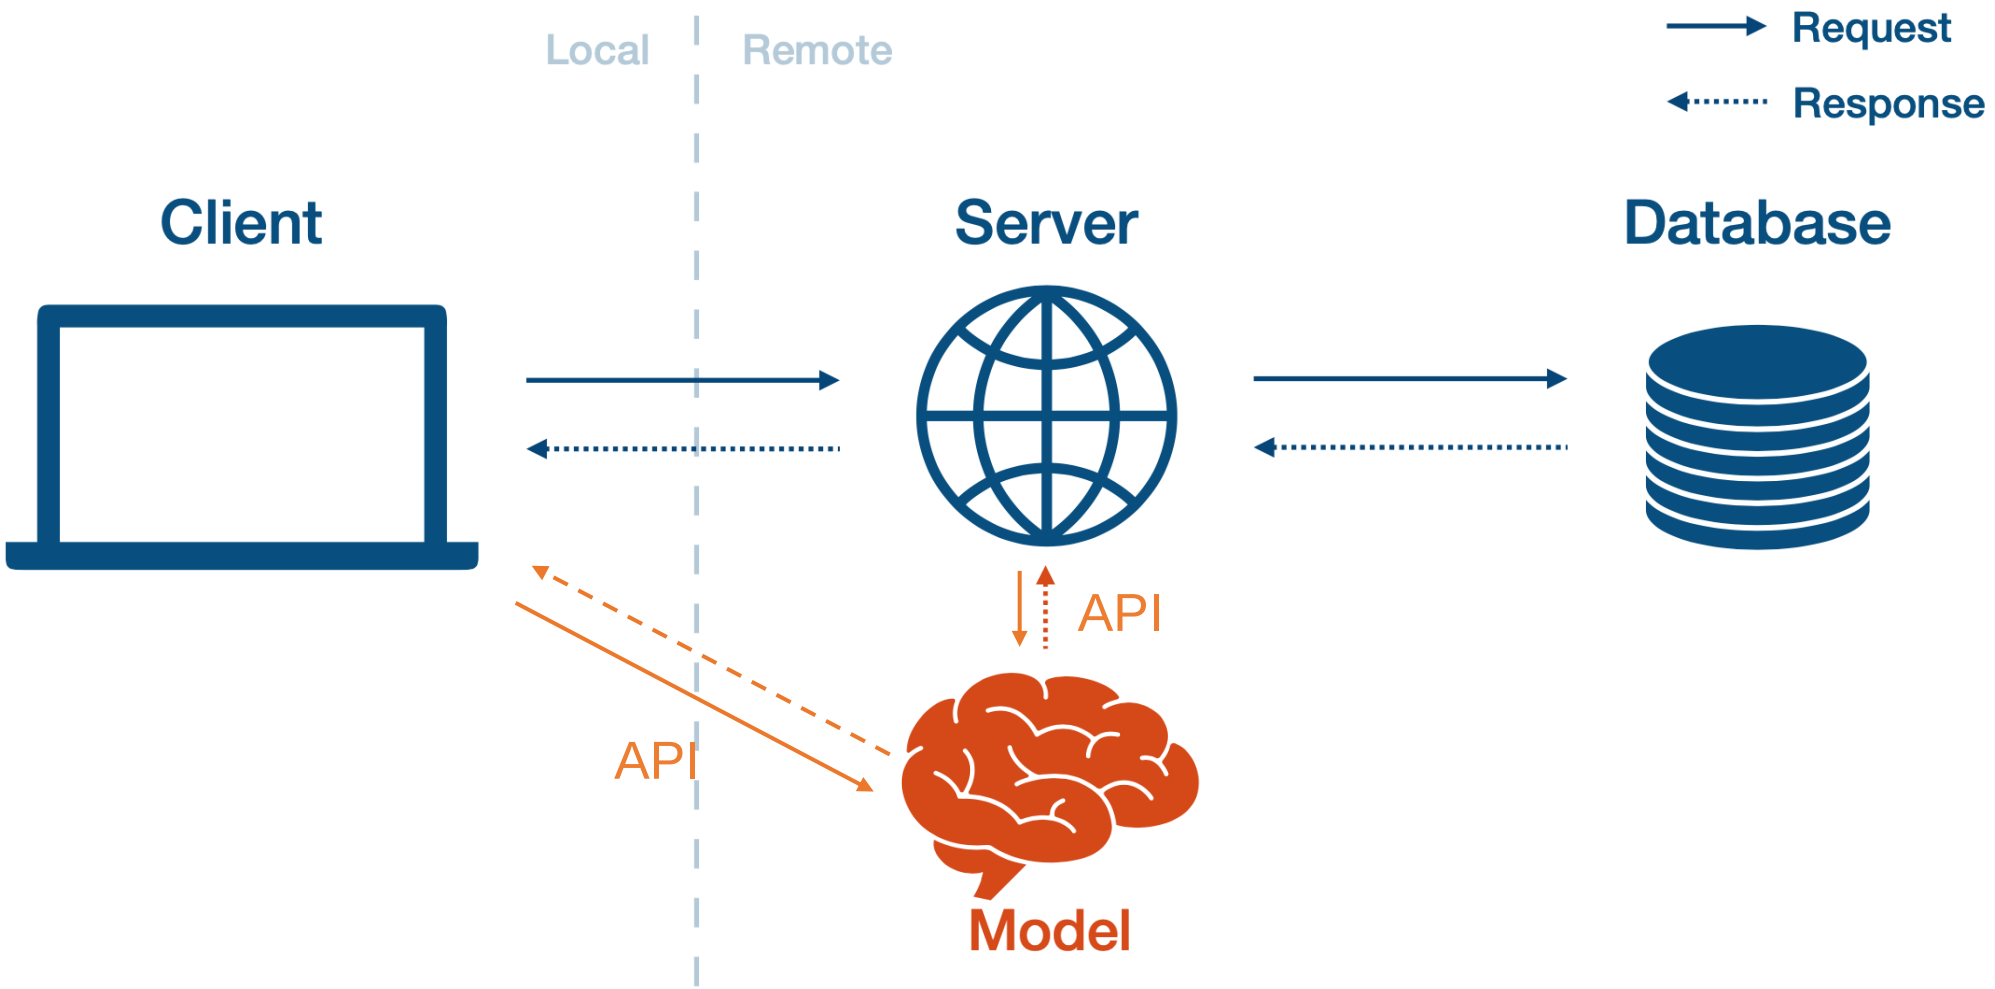

Một số công cụ

Flask

FastAPI

NỘI DUNG

1. Giới thiệu triển khai mô hình máy học
2. Một số cách tiếp cận triển khai mô hình
3. Triển khai dạng ứng dụng web
4. Triển khai dạng dịch vụ (API)
5. Giám sát mô hình

Sau khi triển khai mô hình

- Liệu rằng mô hình độ chính xác cao trên tập validation thì sẽ tốt trên trong quá trình triển khai?

- Một số khả năng xảy ra:
  - Phân bố dữ liệu thay đổi
  - Mô hình bị thay đổi

Một số dạng thay đổi dữ liệu

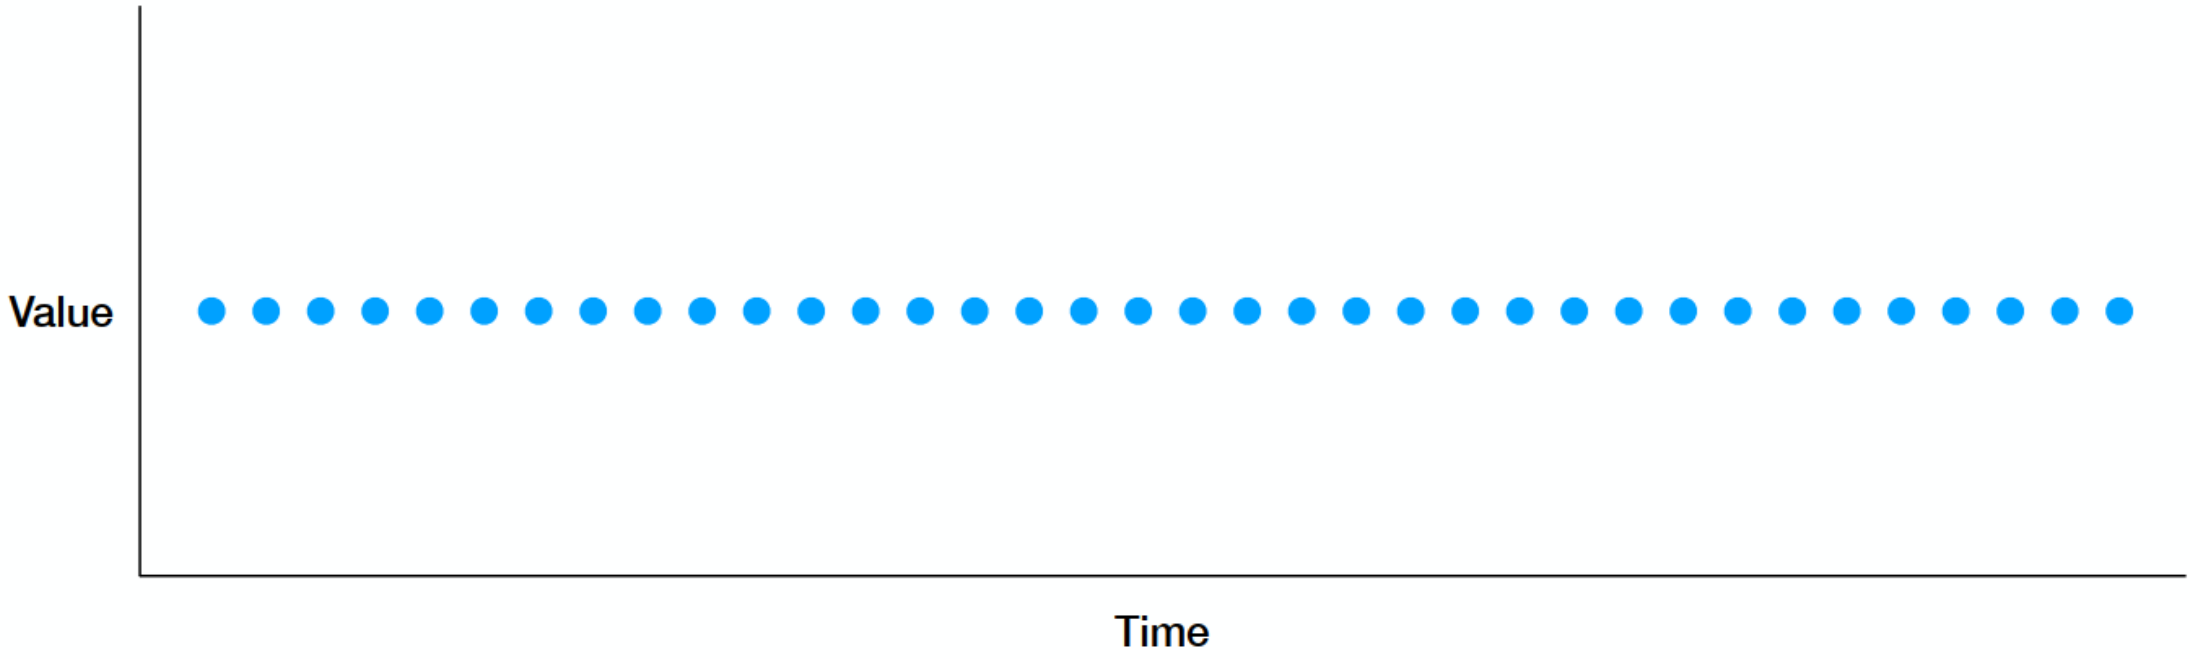

Một số dạng thay đổi dữ liệu

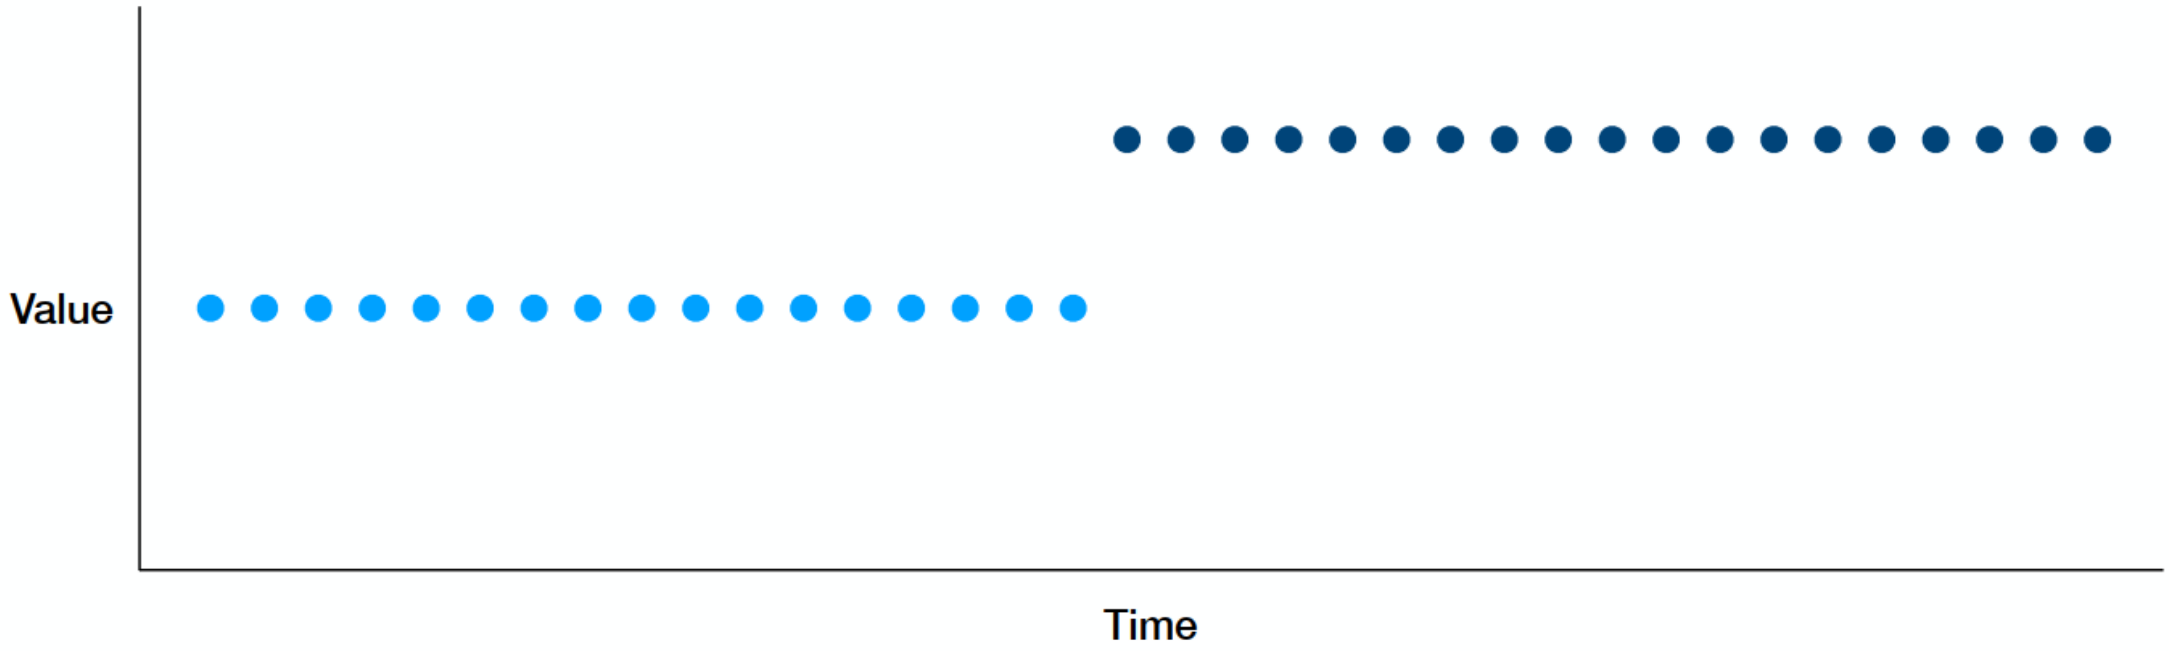

- **Dữ liệu dịch chuyển tức thì** (Instantaneous drift)
  - Do áp dụng trên môi trường khác
  - Biến động chuyển đột ngột của dữ liệu (VD: đại dịch COVID)

Một số dạng thay đổi dữ liệu

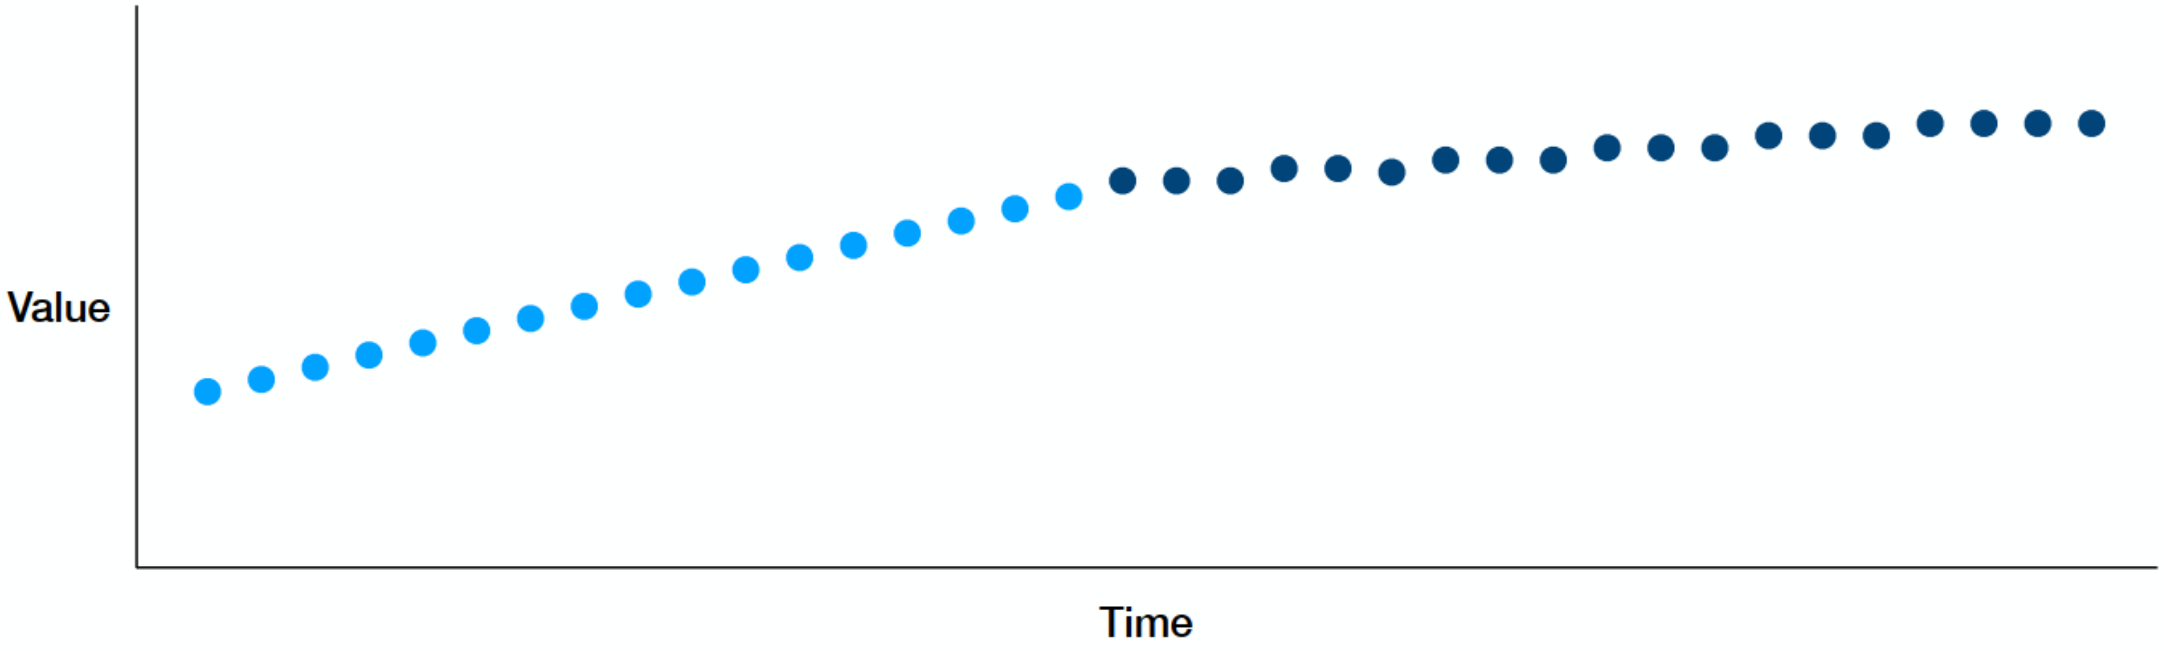

- **Dữ liệu dịch chuyển dần dần** (Gradual drift)
  - Sở thích của người dùng thay đổi theo thời gian
  - Các khái niệm mới xuất hiện theo thời gian

Một số dạng thay đổi dữ liệu

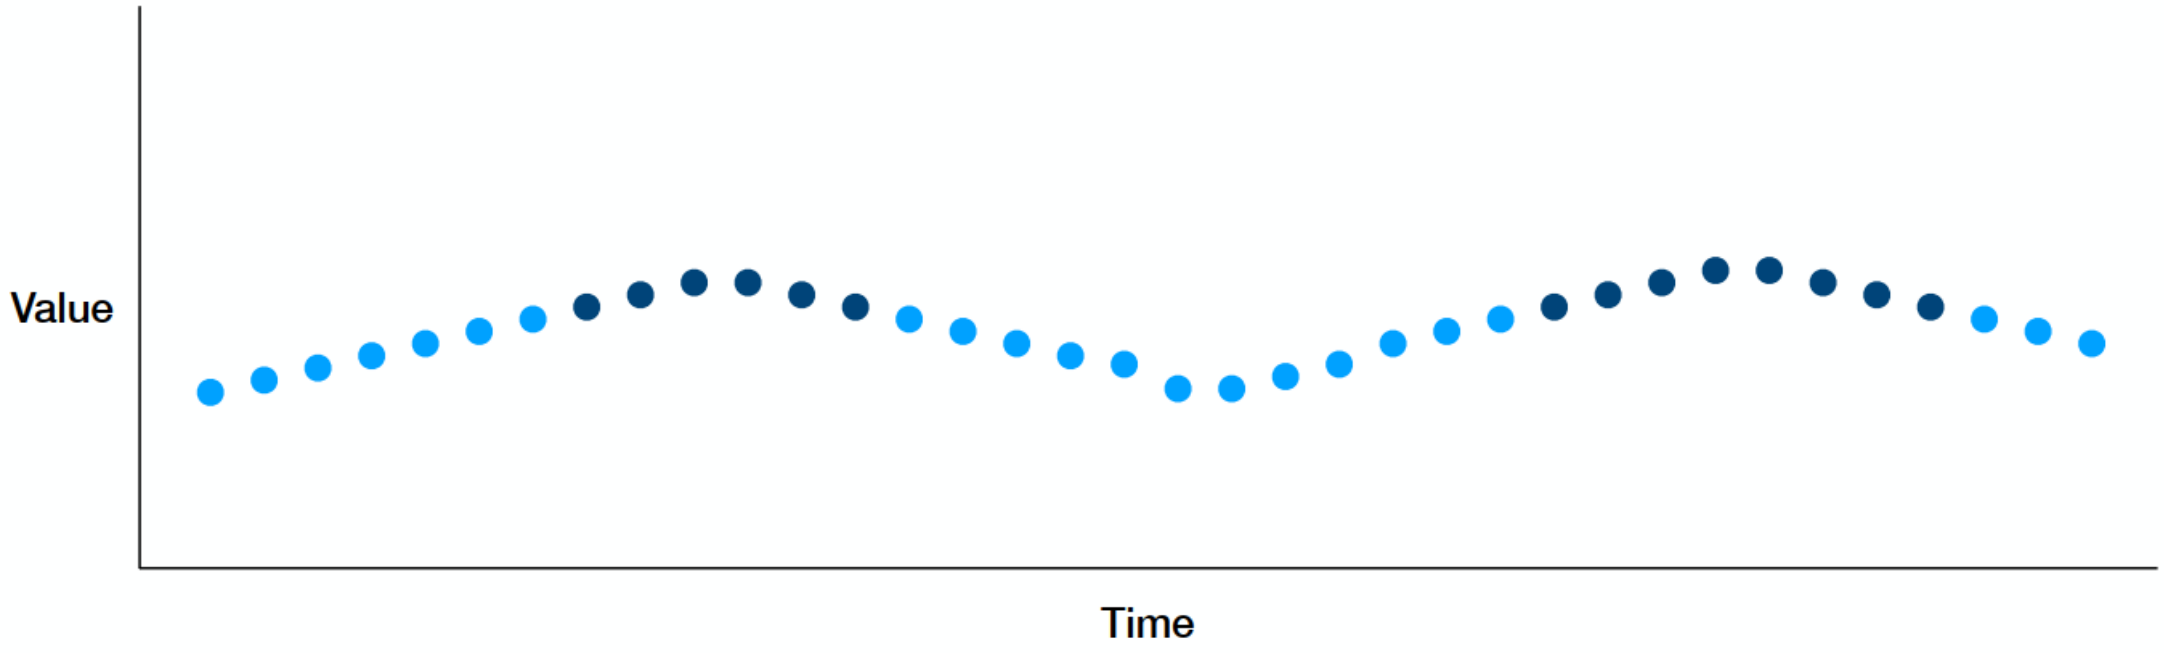

- **Dữ liệu dịch chuyển theo chu kỳ** (Seasonal drift)
  - Sở thích của người dùng thay đổi theo chu kỳ
  - Người dùng ở các múi giờ khác nhau

Một số dạng thay đổi dữ liệu

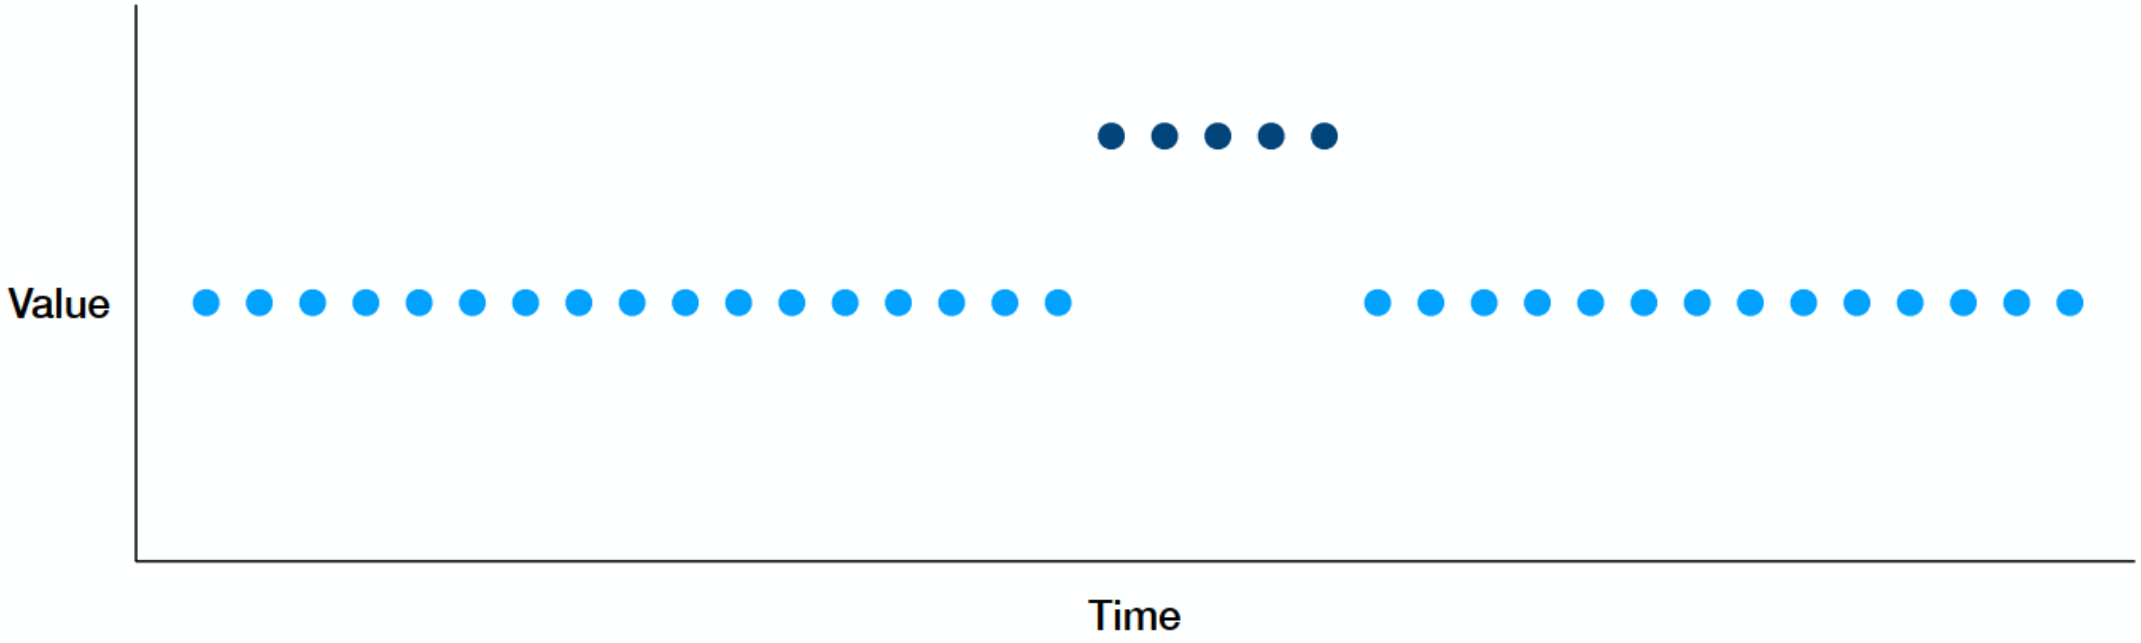

- **Dữ liệu dịch chuyển tạm thời** (Temporary drift)
  - Người dùng độc hại tấn công mô hình
  - Người dùng mới, thuộc nhóm đối tượng mới hoàn toàn

Bốn loại thông tin để giám sát mô hình

More informative

Less informative

- Model metrics (e.g., accuracy)
- Business metrics
- Model inputs and predictions
- System performance

Harder to measure

Easier to measure

Làm sao để giám sát mô hình

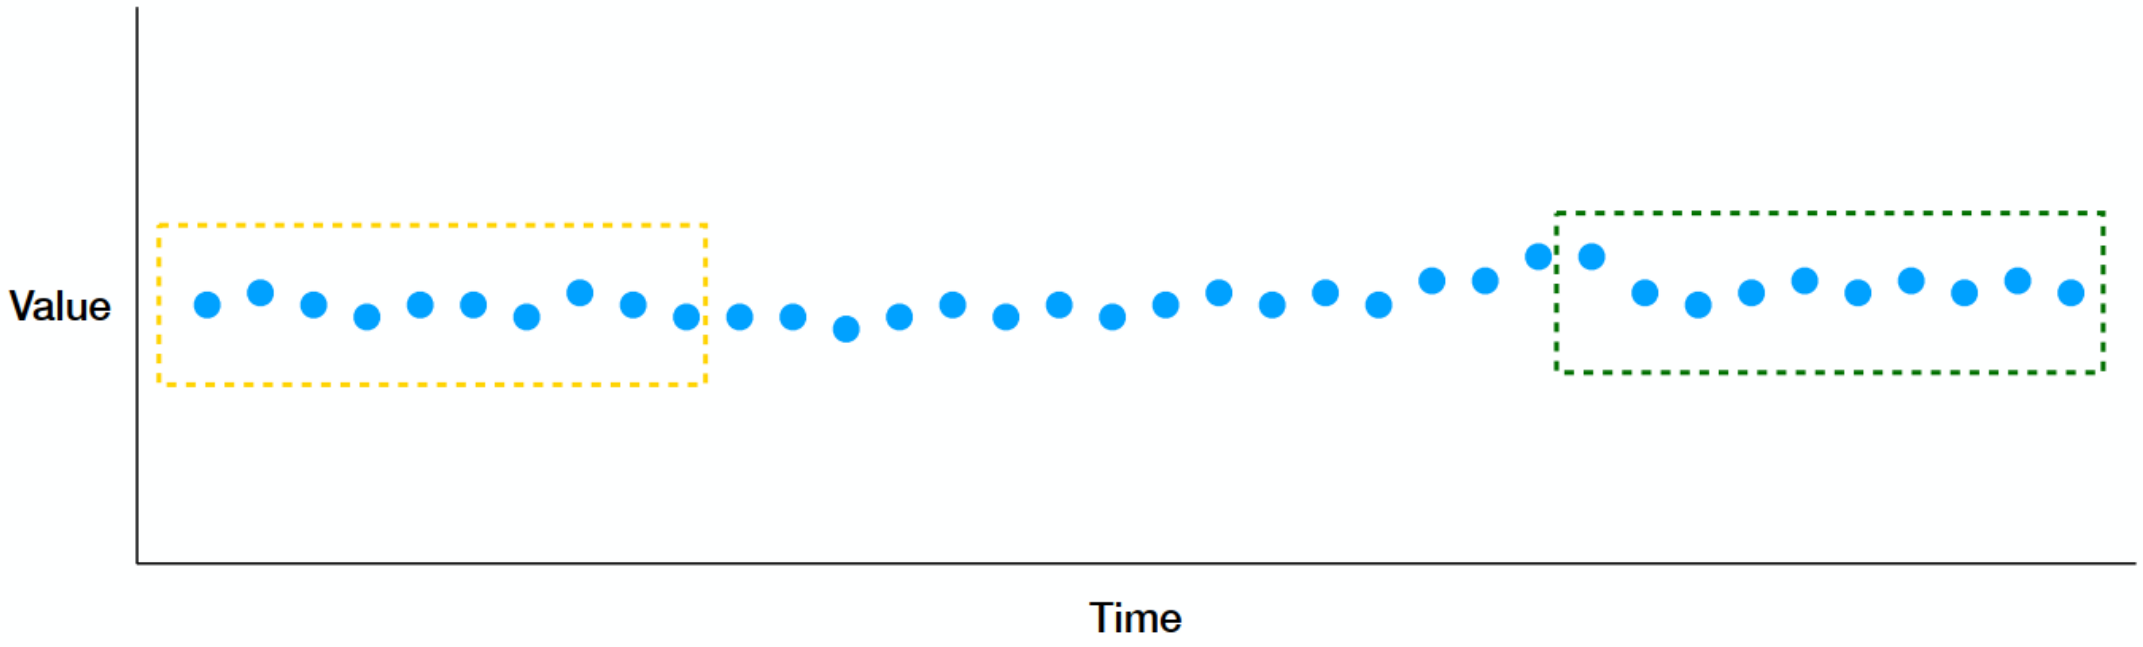

- **Bước 1:** Chọn phạm vi (window) dữ liệu được cho là “tốt” để tham chiếu
- **Bước 2**: Chọn phạm vi mới của dữ liệu để so sánh, đối chiếu
- **Bước 3**: So sánh bằng các metric

BÀI QUIZ VÀ HỎI ĐÁP